

Sentetik Yanık Yaralanması Verisi Üretimi: VGG Perceptual Kayıplı Koşullu Değişken Otokodlayıcı (cVAE)

Berk Burhan Cesur

Öğrenci No: 230212023 · Ders: Derin Öğrenme · Öğretim Üyesi: Dr. Haydar Kılıç

Öz — Tıbbi görüntüleme alanında veri kıtlığı, derin öğrenme modellerinin eğitimini kısıtlayan temel bir sorundur. Bu çalışmada, yanık yaralanması görüntülerini sınıf koşulu ile üretebilen bir Koşullu Değişken Otokodlayıcı (cVAE) geliştirilmiştir. VGG16 özellik çıkarcısına dayalı perceptual kayıp fonksiyonu ile desteklenen model, 1., 2. ve 3. derece yanık sınıfları için sentetik görüntüler üretmektedir. 2.213 örnek içeren veri seti üzerinde 30 epoch eğitim sonucunda en iyi doğrulama kaybı 0.9133 olarak elde edilmiştir. FID skoru değerlendirmesinde cVAE (247.78), standart VAE'yi (282.09) %12.2 oranında geride bırakmıştır. t-SNE ve PCA analizleri ile latent uzayda sınıflar arası ayrışma görselleştirilmiş; sınıflar arası interpolasyon ile modelin sürekli latent uzayı öğrendiği doğrulanmıştır.

Anahtar Kelimeler: Değişken Otokodlayıcı, cVAE, Perceptual Kayıp, VGG16, Sentetik Veri Üretimi, Yanık Sınıflandırması, FID, t-SNE

1. GİRİŞ

Tıbbi görüntü veri setleri; hasta gizliliği, etiketleme maliyeti ve nadir hastalık durumları nedeniyle çoğunlukla sınırlı sayıda örnek içermektedir. Yanık yaralanması tespiti ve sınıflandırması, özellikle 1., 2. ve 3. derece ayrımı için yeterli etiketli veri bulmak güçtür.

Bu çalışmada, var olan yanık görüntü veri setini VGG16 tabanlı perceptual kayıplı bir cVAE ile genişletmek hedeflenmiştir. Model; sınıf etiketini koşul olarak alarak derecesine uygun sentetik yanık görüntüleri üretmekte ve veri dengesizliğini gidermeye katkı sağlamaktadır.

Çalışmanın ana katkıları: (1) standart piksel kaybının ötesine geçen VGG perceptual kayıp entegrasyonu, (2) β anneal stratejisiyle KL ıraksama kontrolü, (3) FID metriği ile nicel değerlendirme ve (4) standart VAE ile karşılaştırmalı analiz.

2. VERİ SETİ VE ÖN İŞLEME

2.1. Veri Kaynağı

Kaggle platformundaki *Skin Burn Dataset* [6] kullanılmıştır. Ham veri setinde 1.225 JPEG görüntü ve 1.441 YOLO formatında etiket dosyası bulunmaktadır. 216 dosya etiket uyumsuzluğu nedeniyle atlanmıştır.

Tablo 1: Veri seti özeti.

Sınıf	Örnek
1. Derece Yanık	872
2. Derece Yanık	987
3. Derece Yanık	354
Toplam	2.213

Stratifye örnekleme ile %75/%15/%10 bölünmesi yapılmıştır. Eğitim:1.661, Doğrulama:331, Test:221. Görüntüler 128×128 piksel boyutuna yeniden ölçeklendirilmiş, ImageNet istatistikleri ile normalize edilmiştir.

3. MODEL MİMARİSİ

3.1. Koşullu Değişken Otokodlayıcı (cVAE) cVAE, standart

VAE'yi [1] sınıf etiketi koşullaması ile

genişletmektedir [2]. Kodlayıcı girdi görüntüsü x ve sınıf etiketi c 'yi birleştirerek latent dağılımın parametrelerini öğrenir:

$$q_{\phi}(z|x,c) = N(\mu, \sigma^2) \quad (1)$$

Çözücü, örneklenen latent vektörü ve sınıf etiketini alarak görüntüyü yeniden oluşturur:

$$p_{\theta}(x|z,c) \quad (2)$$

3.2. Kodlayıcı ve Çözücü

Kodlayıcı dört katlı evrişimli bloktan oluşmaktadır (64→128→256→512 kanal). Her blok Conv2d + BatchNorm + LeakyReLU içermektedir. Latent boyut 128

olarak belirlenmiştir. Çözücü ise simetrik ConvTranspose2d blokları kullanmaktadır.

Tablo 2: Model parametreleri.

Parametre	Değer
Giriş boyutu	$3 \times 128 \times 128$
Latent boyut	128
Temel kanal	64
Toplam parametre	8.756.864
Cihaz	CUDA (GPU)

4. KAYIP FONKSİYONU

4.1. VGG16 Perceptual Kayıp

VGG16'nın [3] ilk 16 katmanından çıkarılan özellik haritaları kullanılmıştır [4]. Bu yaklaşım düşük seviyeli piksel uyuşması yerine yüksek seviyeli görsel özelliklerin öğrenilmesini teşvik eder:

$$\mathcal{L}_{\text{perc}} = \|\phi(\hat{\mathbf{x}}) - \phi(\mathbf{x})\|_2^2 \quad (3)$$

4.2. Toplam Kayıp

$$L = \text{LMSE} + \lambda_p \cdot \mathcal{L}_{\text{perc}} + \beta \cdot \text{LKL} \quad (4)$$

β değeri anneal stratejisiyle her epoch 0.05 artırılarak 1.0'a ulaşacak şekilde ayarlanmıştır.


5. EĞİTİM

Tablo 3: Eğitim hiperparametreleri.

Hiperparametre	Değer
Epoch sayısı	30
Batch boyutu	32
Öğrenme hızı	3×10^{-4}
Optimizör	Adam
Scheduler	CosineAnnealingLR
β başlangıç / artış	0.05 / 0.05

Tablo 4: Seçili epoch kayıp değerleri.


Epoch	β	Train	Val	KL
1	0.05	1.628	1.227	3.766
5	0.25	1.093	0.984	0.391
10	0.50	1.031	0.936	0.216
15	0.75	0.996	0.927	0.151
20	1.00	0.971	0.913	0.110



Şekil 1: Eğitim ve doğrulama kayıp eğrileri (30 epoch). En iyi val loss = 0.9133.

6. DENEYLER VE SONUÇLAR


6.1. Üretilen Görüntüler



Şekil 2: cVAE tarafından üretilen sentetik yanık görüntüleri. Her satır bir yanık derecesini temsil etmektedir.

Şekil 2'de görüldüğü üzere model, her üç yanık derecesi için de görsel açıdan tutarlı sentetik görüntüler üretebilmektedir.

6.2. Latent Uzay Analizi



Şekil 3: Latent uzayın t-SNE (sol) ve PCA (sağ) ile görselleştirilmesi. Renkler yanık derecelerini temsil etmektedir.

Doğrulama setindeki 331 örnek için 128 boyutlu latent vektörler çıkarılmış; t-SNE ve PCA ile 2 boyuta indirgenmiştir. Şekil 3'de görüldüğü üzere, farklı yanık dereceleri latent uzayda anlamlı kümelenmeler oluşturmaktadır.


6.3. Sınıflar Arası İnterpolasyon



Şekil 4: İki sınıf arasında latent uzay interpolasyonu. Kademeli geçiş modelin sürekli latent uzay öğrendiğini doğrulamaktadır.

6.4. FID Skoru ve Model Karşılaştırması Tablo 5: Model karşılaştırması — FID skoru.

Model	FID	İyileşme
Standart VAE	282.09	—
cVAE (Perceptual)	247.78	%12.2



Şekil 5: Standart VAE ve cVAE görüntü kalitesi karşılaştırması.

2.000 gerçek ve 2.000 sentetik görüntü üzerinde hesaplanan FID’de [5] cVAE, standart VAE’ye kıyasla %12.2 iyileşme sağlamıştır.

7. TARTIŞMA

Perceptual kayıp etkisi: VGG16 tabanlı perceptual kayıp, modelin yüksek frekanslı doku ve yapısal özellikleri daha iyi öğrenmesini sağlamıştır. FID’deki %12.2 iyileşme bu katkıyı nicel olarak doğrulamaktadır.

β -anneal stratejisi: KL ağırlığının kademeli artırılması erken eğitimde yeniden oluşturma kalitesini korurken latent uzayın düzenliliğini dengelemiştir. İlk epoch’ta $KL = 3.766$ iken 20. epoch’ta 0.110’a düşmesi başarılı dengelemeyi göstermektedir.

Sınıf dengesizliği: 3. derece yanık örneklerinin (354) az olması bu sınıf için üretim kalitesini olumsuz etkilemiş olabilir. Sentetik veri üretimi tam da bu sorunu gidermek için kullanılabilir.

8. GELECEK ÇALIŞMALAR

GAN entegrasyonu: cVAE çıktıları discriminator ile iyileştirilerek VAE-GAN mimarisi kurulabilir.

Daha yüksek çözünürlük: 256×256 veya 512×512 çözünürlükte üretim klinik kullanım için daha anlamlı olacaktır.

Downstream sınıflandırma: Sentetik görüntülerle eğitilen sınıflandırıcının gerçek veri üzerindeki başarımı ölçülerek veri artırımının faydası nicel olarak kanıtlanabilir.

Diffusion modelleri: DDPM veya Stable Diffusion ile karşılaştırmalı analiz yapılabilir.

9. SONUÇ

Bu çalışmada yanık yaralanması görüntüleri için VGG16 perceptual kayıplı cVAE geliştirilmiştir. 30 epoch eğitim sonunda en iyi doğrulama kaybı 0.9133 elde edilmiş; FID = 247.78 ile standart VAE (282.09) %12.2 geride bırakılmıştır. t-SNE analizi latent uzayda sınıflar arası anlamlı ayrışmayı göstermiş; interpolasyon deneyleri sürekli ve anlamlı bir latent uzay öğrenildiğini doğrulamıştır. Perceptual kayıp ve β -anneal stratejisinin birlikte kullanımı tıbbi görüntü veri artırımı için umut verici bir yaklaşım sunmaktadır.

KAYNAKÇA

Kaynaklar

- [1] D. P. Kingma, M. Welling, “Auto-Encoding Variational Bayes,” *ICLR*, 2014.
- [2] K. Sohn, H. Lee, X. Yan, “Learning Structured Output Representation using Deep Conditional Generative Models,” *NeurIPS*, 2015.
- [3] K. Simonyan, A. Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition,” *ICLR*, 2015.
- [4] J. Johnson, A. Alahi, L. Fei-Fei, “Perceptual Losses for RealTime Style Transfer and Super-Resolution,” *ECCV*, 2016.
- [5] M. Heusel et al., “GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium,” *NeurIPS*, 2017.
- [6] S. Baid, “Skin Burn Dataset,” Kaggle, 2024. <https://www.kaggle.com/datasets/shubhambaid/skin-burn-dataset>